


# MODELAGEM E INFERÊNCIA ESTATÍSTICA

Adequações do modelo e  
modelos não lineares  
Exemplos



# O QUE VOU APRENDER HOJE?

Exemplos práticos

Adequação do Modelo

Modelo intrinsecamente linear



# ADEQUAÇÃO DO MODELO: EXEMPLO 1

Dados sobre  $x$  = taxa de liberação na área do queimador e  $y$  = emissões de NO<sub>x</sub>. Observe os dados e os valores ajustados, os resíduos e os resíduos padronizados. A reta de regressão estimada é  $y = -45,55 + 1,71x$  e  $r^2 = 0,961$ .

```
[4] 1 lstx2 = (100, 125, 125, 150, 150, 200, 200, 250, 250, 300, 300, 350, 400, 400)
    2 lsty2= (150, 140, 180, 210, 190, 320, 280, 400, 430, 440, 390, 600, 610, 670 )
    3 # Construir o DataFrame e nomear as colunas
    4 df = pd.DataFrame(list(zip(lstx2, lsty2)),
    5                     columns =["x","y"])
    6 x=df['x']
    7 y=df['y']
```

	coef	std err	t	P> t	[0.025	0.975]
const	-45.5519	25.468	-1.789	0.099	-101.041	9.938
x	1.7114	0.100	17.168	0.000	1.494	1.929

# ADEQUAÇÃO DO MODELO: EXEMPLO 1

	x	y	yp	e	e*
0	100	150	125.591327	24.408673	0.745861
1	125	140	168.377135	-28.377135	-0.843355
2	125	180	168.377135	11.622865	0.345426
3	150	210	211.162943	-1.162943	-0.033841
4	150	190	211.162943	-21.162943	-0.615821
5	200	320	296.734560	23.265440	0.660343
6	200	280	296.734560	-16.734560	-0.474977
7	250	400	382.306176	17.693824	0.500064
8	250	430	382.306176	47.693824	1.347926
9	300	440	467.877792	-27.877792	-0.800463
10	300	390	467.877792	-77.877792	-2.236128
11	350	600	553.449409	46.550591	1.388367
12	400	610	639.021025	-29.021025	-0.924322
13	400	670	639.021025	30.978975	0.986682

```
1 # Construir o DataFrame e nomear as colunas
2 df = pd.DataFrame(list(zip(x, y, y_pred, resi, standardized_residuals)),
3                     columns=["x", "y", "yp", "e", "e*"])
4 df.head(14)
```

**e\* não é múltiplo de e devido ao fato de que as variâncias residuais são diferentes umas das outras.**

# ADEQUAÇÃO DO MODELO: EXEMPLO 2

## Base de dados GT Auto

```
1 #Observar os dados
2 import io
3 #import pandas as pd
4 df = pd.read_csv(io.StringIO(uploaded['carst.csv'].decode('utf-8')))
5 df.head(30)
6
```


	brand/model/year	cap_vol	consumo	power	weight	cemm	nu_cy	Etype
0	Gurgel BR800 0.8 1991	792	12.0	33	650	34.4	2	0
1	FIAT UNO Mille EP 1996	994	10.4	58	870	18.6	4	0
2	Hyundai HB20 Sense 2020	1000	12.8	80	989	14.5	3	0
3	FIAT Strada 1.4 2016	1368	10.3	86	1084	12.5	4	0
4	Volkswagen GOL 1.6 2015	1598	10.5	104	961	9.8	4	0
5	Chevrolet Cruze LTZ 1.8 2016	1796	8.5	144	1427	10.2	4	0
6	Honda Civic EXR 2016	1997	9.5	155	1294	10.9	4	0
7	Ford Focus 2.0 GLX 2012	1999	9.2	148	1347	10.4	4	0
8	BMW 325i 3.0 2012	2996	6.5	218	1460	7.1	6	0
9	AUDI A4 3.2 V6 Fsi 2011	3197	7.1	269	1610	6.4	6	0
10	Mercedes-Benz CLS 350 3.5 V6 2012	3498	6.6	306	1735	6.1	6	0
11	Mercedes-Benz CLS 500 5.5 V8 2007	5461	4.2	388	1760	5.4	8	0



# ADEQUAÇÃO DO MODELO: EXEMPLO 2

## Base de dados GT Auto

▶	11	Mercedes-Benz CLS 500 5.5 V8 2007	5461	4.2	388	1760	5.4	8	0
	12	Chevrolet Camaro SS 6.2 V8 2018	6162	6.4	461	1709	4.2	8	0
	13	Pagani Zonda F 7.3 V12 2006	7291	3.0	602	1230	3.6	12	0
	14	Volkswagen Polo Highline 1.0 Tsi 2021	999	11.4	128	1147	9.6	3	1
	15	Chevrolet Tracker Premier 1.2 T 2021	1199	11.2	133	1271	9.4	3	1
	16	Chevrolet Cruze LTZ 1.4 T 2021	1399	11.0	153	1321	9.0	4	1
	17	Honda Civic Touring 1.5 T 2021	1498	11.0	173	1329	8.6	4	1
	18	Peugeot 306 Griffé 1.6 THP 2019	1598	10.6	173	1392	8.3	4	1
	19	Audi A4 Attraction 1.8 TFSi 2015	1798	8.7	170	1470	8.3	4	1
	20	BMW 320i Sport 2.0 T 2020	1998	10.5	184	1460	7.1	4	1
	21	Porsche Panamera 3.0 V6 2018	2995	7.8	330	1815	5.7	6	1
	22	Honda NSX 3.5 V6 T 2017	3493	7.0	507	1725	3.3	6	1
	23	Nissan GTR Nismo 3.8 V6 T 2015	3799	5.0	608	1729	2.7	6	1
	24	Mercedes-Benz E63 S AMG 4.0 V8 2021	3982	6.1	612	1935	3.4	8	1
	25	Aston Martin DB11 5.2 V12 T 2017	5204	2.6	608	1770	3.9	12	1
	26	Pagani Huayra 6.0 V12 T 2014	5980	3.0	730	1350	3.3	12	1
	27	Bugatti Chiron 8.0 W16 2016	7993	3.8	1500	1998	2.5	16	1



# ADEQUAÇÃO DO MODELO: EXEMPLO 2

Base de dados GT Auto ☐ Motor aspirado

```
1 df1 = df[df.Etype != 1]
2 df1.head(15)
```

	brand/model/year	cap_vol	consumo	power	weight	cenm	nu_cy	Etype
0	Gurgel BR800 0.8 1991	792	12.0	33	650	34.4	2	0
1	FIAT UNO Mille EP 1996	994	10.4	58	870	18.6	4	0
2	Hyundai HB20 Sense 2020	1000	12.8	80	989	14.5	3	0
3	FIAT Strada 1.4 2016	1368	10.3	86	1084	12.5	4	0
4	Volkswagen GOL 1.6 2015	1598	10.5	104	961	9.8	4	0
5	Chevrolet Cruze LTZ 1.8 2016	1796	8.5	144	1427	10.2	4	0
6	Honda Civic EXR 2016	1997	9.5	155	1294	10.9	4	0
7	Ford Focus 2.0 GLX 2012	1999	9.2	148	1347	10.4	4	0
8	BMW 325i 3.0 2012	2996	6.5	218	1460	7.1	6	0
9	AUDI A4 3.2 V6 Fsi 2011	3197	7.1	269	1610	6.4	6	0
10	Mercedes-Benz CLS 350 3.5 V6 2012	3498	6.6	306	1735	6.1	6	0
11	Mercedes-Benz CLS 500 5.5 V8 2007	5461	4.2	388	1760	5.4	8	0
12	Chevrolet Camaro SS 6.2 V8 2018	6162	6.4	461	1709	4.2	8	0
13	Pagani Zonda F 7.3 V12 2006	7291	3.0	602	1230	3.6	12	0

# ADEQUAÇÃO DO MODELO: EXEMPLO 2

## Reta de regressão

```
1 #adicionar uma constante preditora
2 x = sm.add_constant(x)
3 #fit linear regression model
4 modelo = sm.OLS(y, x).fit() #atenção esta variável será usada no IC
5 print(modelo.summary())
```

```

                    OLS Regression Results
=====
Dep. Variable:      consumo    R-squared:      0.834
Model:              OLS       Adj. R-squared:  0.820
Method:             Least Squares   F-statistic: 60.33
Date:               Tue, 15 Feb 2022   Prob (F-statistic): 5.08e-06
Time:               17:34:00    Log-Likelihood: -21.429
No. Observations:   14         AIC:           46.86
Df Residuals:       12         BIC:           48.14
Df Model:           1
Covariance Type:    nonrobust
=====

```

	coef	std err	t	P> t	[0.025	0.975]
const	11.9686	0.566	21.145	0.000	10.735	13.202
cap_vol	-0.0013	0.000	-7.767	0.000	-0.002	-0.001

```
=====
Omnibus:            1.442    Durbin-Watson:      1.883
Prob(Omnibus):      0.486    Jarque-Bera (JB):    1.002
Skew:               0.615    Prob(JB):            0.606
Kurtosis:           2.548    Cond. No.            6.12e+03
=====
```

```
1 # parâmetros da reta
2 b=modelo.params
3 b0=b[0] #intercepto
4 b1=b[1] #inclinação
5 print('y= {0}{1} x'.format(b0,b1))
```

```
y= 11.968578736702085-0.0012593116220535796 x
```

**$y = 11,9686 - 0,001259x$**   
**x: Capacidade volumétrica.**  
**y: Consumo.**



# ADEQUAÇÃO DO MODELO: EXEMPLO 2

## Resíduos e resíduos padronizados

	x	y	yc	e	e*	e/e*
0	792	12.0	10.971204	1.028796	0.923383	1.114160
1	994	10.4	10.716823	-0.316823	-0.281988	1.123532
2	1000	12.8	10.709267	2.090733	1.860422	1.123795
3	1368	10.3	10.245840	0.054160	0.047584	1.138197
4	1598	10.5	9.956199	0.543801	0.474716	1.145529
5	1796	8.5	9.706855	-1.206855	-1.048677	1.150836
6	1997	9.5	9.453733	0.046267	0.040048	1.155287
7	1999	9.2	9.451215	-0.251215	-0.217440	1.155327
8	2996	6.5	8.195681	-1.695681	-1.457151	1.163696
9	3197	7.1	7.942559	-0.842559	-0.724684	1.162657
10	3498	6.6	7.563507	-0.963507	-0.831048	1.159388
11	5461	4.2	5.091478	-0.891478	-0.821422	1.085286
12	6162	6.4	4.208701	2.191299	2.119047	1.034097
13	7291	3.0	2.786938	0.213062	0.232426	0.916688

x: Capacidade volumétrica.

y: Consumo.


$\hat{y}$ : Valores previsto de y.

e: Resíduos.

e\*: Resíduos padronizados. e/e\*: proporção

# ADEQUAÇÃO DO MODELO: EXEMPLO 2

## Gráficos de diagnóstico




## 1. Reta de regressão e valores observados

```
1 #Gráficos de diagnóstico 1 (y vs. x)  
2 sns.lmplot(x='cap_vol', y='consumo', data=df1);plt.grid(True)
```

# ADEQUAÇÃO DO MODELO: EXEMPLO 2

## Gráficos de diagnóstico



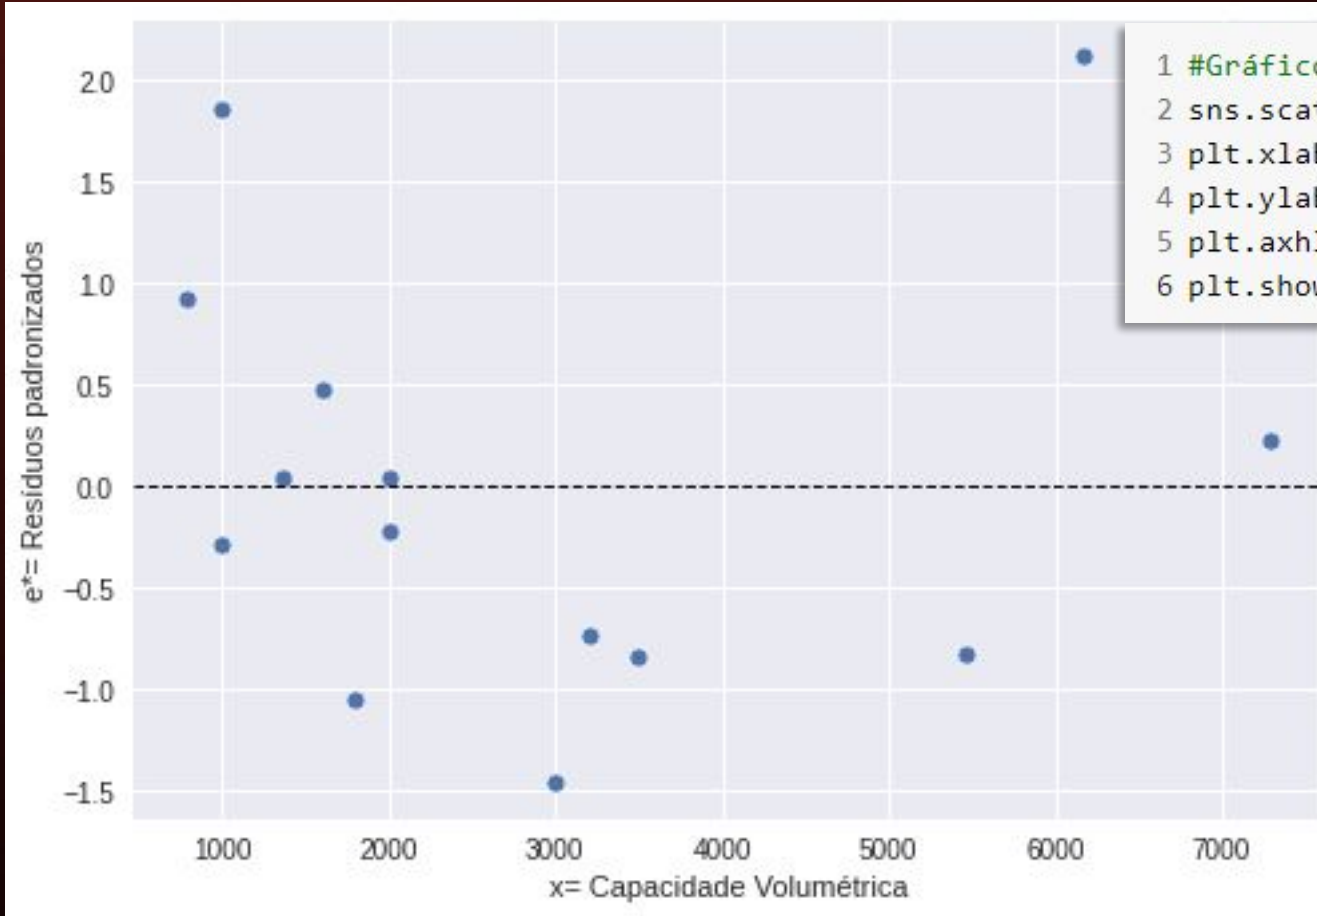
## 2. Valores previstos vs. valores observados

```
1 #Gráficos de diagnóstico 2 (y vs. yc)  
2 sns.lmplot(x='y', y='yc', data=dft);plt.grid(True)
```

# ADEQUAÇÃO DO MODELO: EXEMPLO 2

## Gráficos de diagnóstico

### 3. Resíduos padronizados vs. x




```
1 #Gráficos de diagnóstico 3 (resíduos padronizados vs. x)
2 sns.scatterplot(x='x', y='e*', data=dft);plt.grid(True)
3 plt.xlabel('x= Capacidade Volumétrica')
4 plt.ylabel('e*= Resíduos padronizados')
5 plt.axhline(y=0, color='black', linestyle='--', linewidth=1)
6 plt.show()
```



# ADEQUAÇÃO DO MODELO: EXEMPLO 2

## Gráficos de diagnóstico

### 4. Resíduos padronizados vs. y




```
1 #Gráficos de diagnóstico 4 (resíduos padronizados vs. y)
2 sns.scatterplot(x='y', y='e*', data=dft);plt.grid(True)
3 plt.xlabel('y= Consumo')
4 plt.ylabel('e*= Resíduos padronizados')
5 plt.axhline(y=0, color='black', linestyle='--', linewidth=1)
6 plt.show()
```

# ADEQUAÇÃO DO MODELO: EXEMPLO 2

## Gráficos de diagnóstico

## 5. Gráfico de probabilidade normal



```
1 QQ = ProbPlot(influence.resid_studentized_internal)
2 plot_lm_2 = QQ.qqplot(line='45', alpha=0.5, color='#4C72B0', lw=1)
3 plot_lm_2.axes[0].set_xlabel('Percentil')
4 plot_lm_2.axes[0].set_ylabel('Resíduos padronizados')
```

# MODELO INTRINSECAMENTE LINEAR: EXEMPLO 3

## Enunciado

Nenhum aficionado por batatas fritas gosta que elas fiquem encharcadas, por isso é importante encontrar características do processo de produção que as permitam ter uma textura atraente. Os seguintes dados em que  $x$  = tempo de fritura (s) e  $y$  = teor de umidade (%) apareceram no artigo “Thermal and Physical Properties of Tortilla Chips as a Function of Frying Time” (J. of Food Processing and Preservation, 1995: 175–189). A partir destes dados:


$x$	5	10	15	20	25	30	45	60
$y$	16.3	9.7	8.1	4.2	3.4	2.9	1.9	1.3

- Construa um gráfico de dispersão de  $y$  versus  $x$  e comente.
- Construa um gráfico de dispersão dos pares  $(\ln(x), \ln(y))$  e comente.
- Qual é a relação probabilística entre  $x$  e  $y$  sugerido pelo padrão linear no gráfico da parte (b)?
- Preveja o valor do teor de umidade ao fritar as batatas por 20s, de uma forma que transmita informações sobre confiabilidade e precisão.
- Analise os resíduos do ajuste do modelo de regressão linear para os dados transformados e comente.

# MODELO INTRINSECAMENTE LINEAR: EXEMPLO 3

a) Construa um gráfico de dispersão de  $y$  versus  $x$  e comente.

➤ Os dados podem ser descritos mediante uma reta?





## MODELO INTRINSECAMENTE LINEAR: EXEMPLO 3

**a) Construa um gráfico de dispersão de y versus x e comente.**

**Confira a observação com o procedimento de regressão linear.**

OLS Regression Results						
Dep. Variable:		y	R-squared:		0.657	
Model:		OLS	Adj. R-squared:		0.600	
Method:		Least Squares	F-statistic:		11.48	
Date:		Wed, 16 Feb 2022	Prob (F-statistic):		0.0147	
Time:		03:03:48	Log-Likelihood:		-19.587	
No. Observations:		8	AIC:		43.17	
Df Residuals:		6	BIC:		43.33	
Df Model:		1				
Covariance Type:		nonrobust				
	coef	std err	t	P> t	[0.025	0.975]
const	11.8599	2.079	5.705	0.001	6.773	16.947
x	-0.2242	0.066	-3.389	0.015	-0.386	-0.062
Omnibus:	1.672	Durbin-Watson:	0.824			
Prob(Omnibus):	0.433	Jarque-Bera (JB):	0.817			
Skew:	0.738	Prob(JB):	0.665			
Kurtosis:	2.482	Cond. No.	57.2			


# MODELO INTRINSECAMENTE LINEAR: EXEMPLO 3

b) Construa um gráfico de dispersão dos pares  $(\ln(x), \ln(y))$  e comente.

➤ Observe os valores das variáveis transformadas.

```
1 dfries2 = pd.DataFrame(list(zip(x, y, vtx, vty)),  
2                           columns=["x", "y", "ln_x", "ln_y"])  
3 dfries2.head()
```

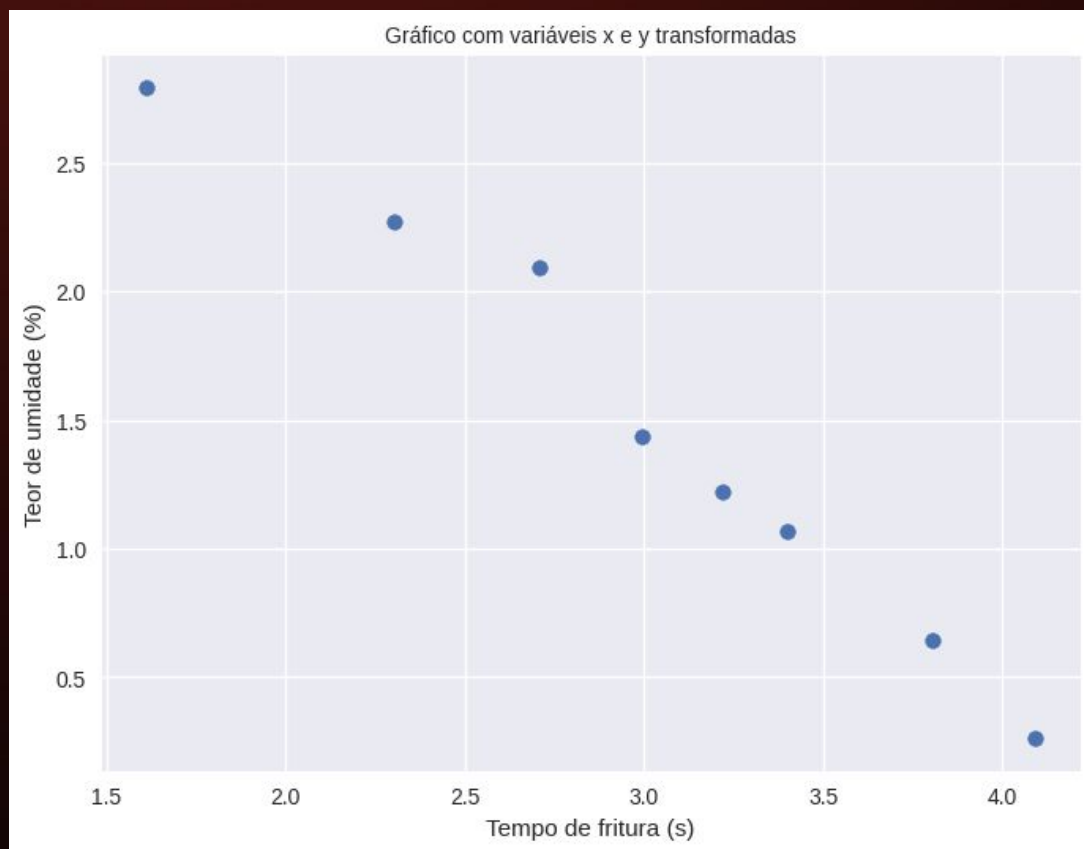
	x	y	ln_x	ln_y
0	5	16.3	1.609438	2.791165
1	10	9.7	2.302585	2.272126
2	15	8.1	2.708050	2.091864
3	20	4.2	2.995732	1.435085
4	25	3.4	3.218876	1.223775



# MODELO INTRINSECAMENTE LINEAR: EXEMPLO 3

b) Construa um gráfico de dispersão dos pares  $(\ln(x), \ln(y))$  e comente.



➤ Observe os valores das variáveis transformadas.



# MODELO INTRINSECAMENTE LINEAR: EXEMPLO 3

c) Qual é a relação probabilística entre  $x$  e  $y$  sugerido pelo padrão linear no gráfico da parte (b)?

Função	Transformações para linearizar	Forma linear



Fonte: (DEVORE, 2018, p. 515)



## MODELO INTRINSECAMENTE LINEAR: EXEMPLO 3

d) Preveja o valor do teor de umidade ao fritar as batatas por 20s, de forma que transmita informações sobre confiabilidade e precisão.

➤ Considerar o procedimento dos mínimos quadrados, mas aplicar às variáveis transformadas para obter a reta:

Forma linear

Depois, aplicar as transformações necessárias para obter a função potência.

Função



# MODELO INTRINSECAMENTE LINEAR: EXEMPLO 3

d) Preveja o valor do teor de umidade ao fritar as batatas por 20s, de forma que transmita informações sobre confiabilidade e precisão.

OLS Regression Results

Dep. Variable:	y	R-squared:	0.976
Model:	OLS	Adj. R-squared:	0.971
Method:	Least Squares	F-statistic:	239.1
Date:	Wed, 16 Feb 2022	Prob (F-statistic):	4.63e-06
Time:	03:42:03	Log-Likelihood:	5.2525
No. Observations:	8	AIC:	-6.505
Df Residuals:	6	BIC:	-6.346
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
const	4.6384	0.211	21.978	0.000	4.122	5.155
x	-1.0492	0.068	-15.462	0.000	-1.215	-0.883

Omnibus:	8.964	Durbin-Watson:	1.881
Prob(Omnibus):	0.011	Jarque-Bera (JB):	2.783
Skew:	1.325	Prob(JB):	0.249
Kurtosis:	4.154	Cond. No.	14.1

# MODELO INTRINSECAMENTE LINEAR: EXEMPLO 3

d) Preveja o valor do teor de umidade ao fritar as batatas por 20s, de forma que transmita informações sobre confiabilidade e precisão.

➤ Resultado inicial:

Forma linear	

Voltando para as variáveis originais:

Função	

# MODELO INTRINSECAMENTE LINEAR: EXEMPLO 3

d) Preveja o valor do teor de umidade ao fritar as batatas por 20s, de forma que transmita informações sobre confiabilidade e precisão.

➤ Para  $x=20s$  quanto vale  $y$ ?

Forma linear

Função potência

Esta informação é suficiente para ter noção de confiabilidade e precisão?





# MODELO INTRINSECAMENTE LINEAR: EXEMPLO 3

d) Preveja o valor do teor de umidade ao fritar as batatas por 20s, de forma que transmita informações sobre confiabilidade e precisão.

➤ Para  $x=20s$ , quanto vale  $y$ ?  
A equação do IP:

$$\hat{y}' \pm t_{\frac{\alpha}{2}, n-2} \sqrt{s^2 - s_{\hat{y}}^2}$$

Necessário calcular:  $t_{\frac{\alpha}{2}, n-2}$ ,  $s^2$  e  $s_{\hat{y}}^2$

$$\hat{\sigma}^2 = s^2 = \frac{SQE}{n-2} = \frac{\sum (y_i - \hat{y}_i)^2}{n-2}$$

$$S_Y = s \sqrt{\frac{1}{n} + \frac{(x^* - \bar{x})^2}{S_{xx}}}$$

Forma linear	Função potência

# MODELO INTRINSECAMENTE LINEAR: EXEMPLO 3

d) Preveja o valor do teor de umidade ao fritar as batatas por 20s, de forma que transmita informações sobre confiabilidade e precisão.

➤ Para  $x=20s$ , quanto vale  $y$ ?  
A equação do IP:

$$\hat{y}' \pm t_{\frac{\alpha}{2}, n-2} \sqrt{s^2 - s_{\hat{y}}^2}$$

Necessário calcular:

$$t_{\frac{\alpha}{2}, n-2} = 2,4469$$

Forma linear	Função potência

```
1 #@title Resposta d)
2 #usar a tabela tstudent para t
3 from scipy.stats import t
4 alpha = 0.05 # nível de significância
5 df = len(x) - 2 # gl (n - 2)
6 v = t.ppf(1 - alpha/2, df)
7 print(f't=: {v}')
```

t=: 2.4469118487916806

# MODELO INTRINSECAMENTE LINEAR: EXEMPLO 3

d) Preveja o valor do teor de umidade ao fritar as batatas por 20s, de forma que transmita informações sobre confiabilidade e precisão.

➤ Para  $x=20s$ , quanto vale  $y$ ?

Forma linear

Função potência

```
1 x=dfries['x']
2 y=dfries['y']
3 vtx=np.log(x)
4 vty=np.log(y)
5 y_pred=list(modelo.predict())
6 #sns.resid(modelo)
7 resi=(modelo.resid)
8 #SQE = residuos ao quadrado
9 sqe=np.sum(resi*resi)
10 gl=modelo.df_resid #gl=n-2
11 s2=sqe/gl
12 s=pow(s2,1/2)
13 sqe,s2,s
```

A equação do IP

$$\hat{y}' \pm t_{\alpha/2, n-2} \sqrt{s^2 - s_{\hat{y}}^2}$$

Necessário calcular:  $s$

$$SQE = \sum (y_i - \hat{y}_i)^2$$

$$s^2 = \frac{SQE}{n-2} = \frac{0,12599}{8-2}$$
$$= 0,020998$$

$$s = \sqrt{s^2} = 0,125989$$

(0.1259894484543931, 0.02099824140906552, 0.14490769961967348)

# MODELO INTRINSECAMENTE LINEAR: EXEMPLO 3

d) Preveja o valor do teor de umidade ao fritar as batatas por 20s, de forma que transmita informações sobre confiabilidade e precisão.

➤ Para  $x=20s$ , quanto vale  $y$ ?  
A equação do IP:

$$\hat{y}' \pm t_{\alpha/2, n-2} \sqrt{s^2 - s_{\hat{y}}^2}$$

Necessário calcular:  $s_{\hat{y}}^2$

```
1 vtxs=np.log(20) #x*=ln(20)
2 vtxm=vtx.mean()
3 n=modelo.df_resid + 2 #gl+2=n
4 xx=np.sum(vtx*vtx)
5 xau=np.sum(vtx)
6 sxx=xx-xau*xau/n
7 sy=s*pow((1/n)+(vtxs-vtxm)*(vtxs-vtxm)/sxx),1/2)
8 sy
```

0.05125314354652712

$$s_{\hat{y}} = s \sqrt{\frac{1}{n} + \frac{(x^* - \bar{x})^2}{s_{xx}}} = 0,51253$$

Forma linear

Função potência

# MODELO INTRINSECAMENTE LINEAR: EXEMPLO 3

d) Preveja o valor do teor de umidade ao fritar as batatas por 20s, de forma que transmita informações sobre confiabilidade e precisão.

➤ Para  $x=20s$ , quanto vale  $y$ ?  
A equação do IP:

$$\hat{y}' \pm t_{\frac{\alpha}{2}, n-2} \sqrt{s^2 - s_{\hat{y}}^2}$$

$$\hat{y}' \pm t_{\frac{\alpha}{2}, n-2} \sqrt{s^2 - s_{\hat{y}}^2} = 2,9957 \pm (2,4469)$$

$$\sqrt{0,020998 - 0,51253^2}$$

IP:  $\hat{Y}' = (1,119196, 1,871399)$

$$1,119196 < \hat{Y}' < 1,871399$$

Voltando para as variáveis originais:

IP:  $\hat{Y}' = (3,062392, 6,497386)$

$$3,062392 < \hat{Y} < 6,497386$$

Forma linear

Função potência



# MODELO INTRINSECAMENTE LINEAR: EXEMPLO 3

e) Analise os resíduos do ajuste do modelo de regressão linear para os dados transformados e comente.


➤ Para as variáveis transformadas  $\ln(x)$  e  $\ln(y)$

	x	y	yc	e	e*	e/e*
0	1.609438	2.791165	2.949796	-0.158631	-1.649456	0.096171
1	2.302585	2.272126	2.222547	0.049579	0.391681	0.126580
2	2.708050	2.091864	1.797134	0.294730	2.200852	0.133916
3	2.995732	1.435085	1.495298	-0.060214	-0.444247	0.135541
4	3.218876	1.223775	1.261176	-0.037401	-0.277341	0.134855
5	3.401197	1.064711	1.069885	-0.005174	-0.038898	0.133019
6	3.806662	0.641854	0.644472	-0.002618	-0.021025	0.124511
7	4.094345	0.262364	0.342636	-0.080272	-0.703222	0.114149



# MODELO INTRINSECAMENTE LINEAR: EXEMPLO 3

e) Analise os resíduos do ajuste do modelo de regressão linear para os dados transformados e comente.



# MODELAGEM E INFERÊNCIA ESTATÍSTICA

Adequações do modelo e  
modelos não lineares  
Exemplos

